REPUBLIQUE DU CAMEROUN
REPUBLIC OF CAMEROON
Peace-Work-Fatherland
****
UNIVERSITE DE DSCHANG
UNIVERSITY OF DSCHANG
Scholae Thesaurus Dschangensis Ibi Cordum

B.P.: 96 Dschang-Cameroun
Tel. /Fax (237) 233 45 13 81
Website : http://www.univ-dschang.org
Email : udsrectorat@univ-dschang.org

FACULTE DES SCIENCES
FACULTY OF SCIENCE

Département de Mathématique et Informatique
Department of mathematics and Computer Science

B.P.: 96 Dschang-Cameroun
Tel. /Fax (237) 233 45 13 81
Website : http://fs.univ-dschang.org
Email : dept.math-info@univ-dschang.org

EXPLOITATION DES DONNÉES À L'AIDE DES MODÈLES D'IA

RAPPORT DE SCIENCE DES DONNÉES

Supervisé par :

Dr. AZANGUEZET QUIMATIO Benoît Martin

Année Universitaire 2025–2026

Composition du groupe

Matricules et noms & prénoms des membres

Matricule	Noms & prénoms
CM-UDS-21SCI0124	LOMOFOUET NDONGMO Handrey JAURESS
CM-UDS-20SCI1094	DONGMO ARNOLD JOSPIN
CM-UDS-21SCI1070	KAMGA DZUKAM LOICSTEVEN
CM-UDS-21SCI0460	NANGO IDRISS ROCHENEL
CM-UDS-20SCI0877	KEMADJEU NGOUNOU BERNARD C.
CM-UDS-24SCI0686	KALZIBE DOMINIQUE
CM-UDS-21SCI1432	NGUIMDO KENFACK JELF
CM-UDS-21SCI0195	NONA FOGHAP CONSTANTIN
CM-UDS-24SCI0623	YUMKAM SIMO Elvira Audrey
CM-UDS-22SCI1176	NGO KANDA SABINE FRANCINE ALEXANDRIE
CM-UDS-24SCI0763	PEUHTAO GNEBE TCHINCHACKE
CM-UDS-21SCI0744	FOSSO TIOFOUET CABREL

Table des matières

Introduction Générale **1**

1 Fondements Théoriques de l'Exploitation des Données **3**

1.1 Introduction 3

1.2 Notion de Donnée et Types de Données 4

1.2.1 Définition et portée conceptuelle 4

1.2.2 Taxonomie des données selon leur degré de structuration 4

1.3 Science des Données et Exploitation des Données 5

1.3.1 Définition et périmètre disciplinaire 6

1.3.2 Les quatre niveaux d'analyse 6

1.4 Qualité des Données et Préparation 7

1.4.1 Principales pathologies affectant les données 7

1.4.2 Les techniques de préparation des données 8

1.5 Cycle de Vie et Processus d'Exploitation des Données 8

1.5.1 Le cycle de vie des données 8

1.5.2 Vue d'ensemble de la chaîne de traitement 9

1.6 Limites des Approches Classiques et Nécessité de l'IA 10

1.6.1 Le contexte du Big Data 10

1.6.2 Limites analytiques des méthodes traditionnelles 10

1.6.3 L'apport de l'intelligence artificielle 11

1.7 Conclusion 12

2 Les Modèles d'IA au Service de l'Exploitation des Données **13**

2.1 Intelligence Artificielle, Machine Learning et Deep Learning 13

2.1.1 Définitions et relations hiérarchiques 13

2.2 Modèles Supervisés 15

2.2.1 Régression 15

2.2.2 Classification 16

2.3 Modèles Non Supervisés 17

2.3.1 Clustering 17

2.3.2 Réduction de Dimensionnalité 18

2.4 Réseaux de Neurones et Deep Learning 18

2.4.1 Architecture d'un réseau de neurones 18
2.4.2 Apprentissage par rétropropagation 19
2.4.3 Principales architectures de deep learning 20
2.5 Critères de Choix d'un Modèle 20
2.6 Conclusion 21

3 Méthodologie d'Exploitation des Données avec les Modèles d'IA 22
3.1 Vue d'Ensemble : Le Pipeline MLOps 22
3.2 Définition du Problème à Résoudre 23
3.3 Collecte et Compréhension des Données 23
3.4 Prétraitement des Données 24
3.4.1 Nettoyage des données 24
3.4.2 Encodage des variables catégorielles 24
3.4.3 Normalisation et standardisation 25
3.4.4 Séparation entraînement / validation / test 25
3.5 Analyse Exploratoire des Données (EDA) 25
3.5.1 Statistiques descriptives 25
3.5.2 Visualisations clés 25
3.6 Entraînement des Modèles 26
3.6.1 Stratégie d'apprentissage 26
3.6.2 Réglage des hyperparamètres 26
3.7 Évaluation des Performances 26
3.7.1 Métriques pour la régression 27
3.7.2 Détection du surapprentissage et sous-apprentissage 27
3.8 Interprétation et Exploitation des Résultats 27
3.8.1 Interprétabilité des modèles 28
3.8.2 Du modèle à la décision 28
3.9 Conclusion 28

4 Application Pratique : Prédiction du Rendement Agricole — Plateforme AgriYield 29
4.1 Justification du thème et du cas d'usage 29
4.2 Architecture technique implémentée 29
4.2.1 Vue microservices 30
4.2.2 Flux décisionnel 31
4.3 Description claire de chaque page de la plateforme 32
4.3.1 Accueil + gouvernance latérale 32
4.3.2 Page "Simulateur" 33
4.3.3 Page "Alertes & Décisions" 33
4.3.4 Page "Performances Modèles" 34
4.3.5 Page "Gestion Modèles" 34

4.4 Pourquoi Random Forest apparaît meilleur que XGBoost selon la baseline . . 35
4.4.1 État réel du registre de modèles 35
4.5 Intérêt de comparer plusieurs algorithmes 36
4.5.1 Comparaison intra-baseline (algorithmes candidats) 36
4.6 Prétraitement et analyses de données (modèle de base) 37
4.6.1 Couverture du dataset 37
4.6.2 Courbe de volume annuel et fenêtre de test temporelle 38
4.6.3 Évolution du rendement moyen global 38
4.6.4 Courbe de prétraitement : effet de la standardisation 39
4.7 Fine-tuning : clarification opérationnelle 39
4.7.1 Mécanisme implémenté 39
4.7.2 Règle de couverture temporelle (point important) 39
4.8 Conclusion 40

5 Enjeux, Limites et Perspectives 41
5.1 Apports des Modèles d'IA dans l'Exploitation des Données 41
5.1.1 Capacité prédictive supérieure 41
5.1.2 Automatisation et scalabilité 41
5.1.3 Découverte de connaissances cachées 42
5.1.4 Aide à la décision en temps réel 42
5.2 Limites Rencontrées 42
5.2.1 Limites liées aux données 42
5.2.2 Limites liées aux modèles 42
5.3 Enjeux Éthiques et Sécuritaires 43
5.3.1 Confidentialité et souveraineté des données 43
5.3.2 Équité et biais algorithmiques 43
5.3.3 Transparence et responsabilité 44
5.3.4 Risque de dépendance technologique 44
5.4 Perspectives d'Amélioration 44
5.4.1 Intégration de données en temps réel 44
5.4.2 Modèles plus avancés 45
5.4.3 Explicabilité (XAI) 45
5.4.4 MLOps et déploiement opérationnel 45
5.4.5 Extension géographique et culturelle 45
5.5 Conclusion 46

Conclusion Générale 47

Références Bibliographiques 49

Table des figures

1.1 Les trois piliers de la Science des Données : Mathématiques, Informatique et Expertise Métier 6
1.2 Cycle de vie des données : de la création à la réutilisation 9
1.3 Les cinq dimensions critiques du Big Data 10

2.1 Relation hiérarchique entre IA, Machine Learning et Deep Learning 14
2.2 Comparaison des modèles de régression : Linéaire, Random Forest et Gradient Boosting 16
2.3 Apprentissage supervisé (classification étiquetée) vs. non supervisé (clustering) 17
2.4 Architecture d'un réseau de neurones artificiel multicouche (MLP) 19

3.1 Pipeline complet MLOps : de la donnée brute au modèle en production 22
3.2 Méthodologie CRISP-DM : processus itératif de science des données 23
3.3 Validation croisée à K=5 plis (K-Fold Cross Validation) 26
3.4 Sous-apprentissage, apprentissage optimal et sur-apprentissage (overfitting) . 27

4.1 Architecture microservices de la plateforme AgriYield 30
4.2 Page d'accueil, modèle actif et panneau de confiance 32
4.3 Simulation de scénarios climatiques et analyse de sensibilité 33
4.4 Alertes métier et recommandations d'action 33
4.5 Importance des variables pour le modèle actif 34
4.6 Catalogue des versions de modèles et gouvernance 34
4.7 Niveaux de performance (R^2) des versions baseline 36
4.8 Comparaison des algorithmes sur la même baseline 37
4.9 Distribution annuelle des observations et zone test 2018–2024 38
4.10 Tendance annuelle du rendement moyen global 38
4.11 Impact de la standardisation Z-score : distribution brute (gauche) et valeurs standardisées (droite) 39

5.1 Les six piliers de l'IA Responsable et Éthique pour AgriYield 43
5.2 Perspectives et tendances de développement pour AgriYield 44

Liste des tableaux

1.1 Comparaison des trois catégories de données 5
1.2 Les quatre niveaux d'analyse en science des données 7
1.3 Principales techniques de préparation des données 8
1.4 Positionnement de l'IA dans la chaîne d'exploitation des données 11

2.1 Positionnement de l'IA, du ML et du DL 14
2.2 Principales architectures de réseaux de neurones profonds 20
2.3 Critères de choix d'un modèle d'IA 20

3.1 Dictionnaire de données pour la prédiction du rendement agricole 24
3.2 Métriques d'évaluation pour les problèmes de régression 27

4.1 Services, ports et responsabilités 31
4.2 Comparaison des versions baseline présentes dans le registre 35
4.3 Performance des algorithmes sur la baseline active/référence du rapport . . . 36

Introduction Générale

L'essor considérable des technologies numériques au cours des deux dernières décennies a engendré une production massive de données dans pratiquement tous les secteurs d'activité : santé, agriculture, finance, industrie, transport et administration publique. Cette accumulation exponentielle d'informations, souvent désignée sous le terme de *Big Data*, constitue à la fois une opportunité et un défi. Une opportunité, car ces données recèlent des connaissances précieuses susceptibles d'éclairer la prise de décision ; un défi, car leur volume, leur variété et leur vélocité dépassent les capacités des méthodes d'analyse traditionnelles.

C'est dans ce contexte que la **science des données** s'est imposée comme une discipline à part entière, à l'intersection de l'informatique, des statistiques et de l'expertise métier. Elle propose un ensemble de méthodes et d'outils permettant d'extraire de la valeur à partir de données brutes, en passant par des étapes structurées de collecte, de nettoyage, d'exploration, de modélisation et de restitution des résultats. Parmi les outils les plus puissants dont dispose cette discipline figurent les **modèles d'intelligence artificielle (IA)**, qui offrent la capacité de détecter automatiquement des régularités, d'effectuer des prédictions et de soutenir des processus décisionnels complexes.

Ce rapport s'inscrit dans le cadre du module de Science des Données du **Master 2 en Informatique, option Intelligence Artificielle**, à l'Université de Dschang. Il a pour objectif de présenter, de manière structurée et rigoureuse, les fondements théoriques et méthodologiques de l'exploitation des données à l'aide des modèles d'IA, puis de les illustrer à travers une application concrète : la **prédiction du rendement agricole** pour faciliter la prise de décision, concrétisée sous forme de la plateforme **AgriYield**.

Le choix de cette application n'est pas anodin. L'agriculture constitue un pilier économique fondamental pour de nombreux pays, en particulier en Afrique subsaharienne, où elle emploie une part importante de la population active et contribue significativement au produit intérieur brut. La capacité à anticiper les rendements agricoles à partir de données climatiques, agronomiques et géographiques représente un levier stratégique pour la sécurité alimentaire, l'allocation optimale des ressources et la planification des politiques publiques.

Le présent rapport est organisé autour de **cinq chapitres complémentaires** :

— Le **Chapitre I** pose les fondements théoriques de l'exploitation des données, en clarifiant les notions essentielles relatives aux types de données, à leur cycle de vie et aux exigences de qualité qui conditionnent la fiabilité des analyses.
— Le **Chapitre II** présente les grandes familles de modèles d'intelligence artificielle mobilisables dans un projet de science des données, en distinguant les approches supervisées, non supervisées et les réseaux de neurones profonds.
— Le **Chapitre III** décrit la méthodologie opérationnelle d'exploitation des données avec les modèles d'IA, depuis la formulation du problème jusqu'à l'évaluation et l'interprétation des résultats.
— Le **Chapitre IV** constitue l'application pratique du rapport : il mobilise les concepts et méthodes des chapitres précédents pour construire un système de prédiction du rendement agricole à partir d'un jeu de données réel (FAO/Kaggle).
— Le **Chapitre V** propose une prise de recul critique sur les apports, les limites et les perspectives des modèles d'IA dans l'exploitation des données.

À travers cette progression, le rapport vise à offrir une vision à la fois théorique et appliquée de la science des données, en montrant comment les modèles d'IA peuvent être concrètement mis au service de problématiques réelles à fort impact sociétal.

Chapitre 1

Fondements Théoriques de l'Exploitation des Données

Objectif du chapitre
Clarifier les notions essentielles liées aux données, à leur cycle de vie et aux contraintes de qualité qui conditionnent la pertinence des analyses. Ce chapitre établit le socle conceptuel sur lequel reposent les modèles et méthodes présentés dans la suite du rapport.

1.1 Introduction

L'avènement du numérique et la généralisation des systèmes interconnectés ont conduit à une production massive de données de toutes natures. Qu'il s'agisse de transactions financières, de relevés de capteurs industriels, d'images médicales ou de textes issus des réseaux sociaux, la donnée est devenue la matière première d'une nouvelle économie de la connaissance. Cette réalité a profondément transformé les pratiques scientifiques et industrielles, en faisant de la capacité à traiter et à exploiter l'information une compétence stratégique fondamentale.

Dans ce contexte, la science des données s'est constituée en discipline à part entière, à l'intersection des statistiques, de l'informatique et des domaines applicatifs. Son ambition est de transformer des données brutes, souvent incomplètes et hétérogènes, en connaissances exploitables pour la prise de décision. L'intelligence artificielle, et plus particulièrement l'apprentissage automatique, joue dans ce cadre un rôle de premier plan, en fournissant des méthodes capables d'extraire des patterns complexes là où les approches classiques atteignent leurs limites.

Le présent chapitre aborde successivement la notion de donnée et les différentes catégories qui la composent, les objectifs et le cycle de vie de la science des données, les enjeux de

qualité et les techniques de préparation, la chaîne générale d'exploitation, et enfin les limites des approches classiques qui motivent le recours aux méthodes d'intelligence artificielle.

1.2 Notion de Donnée et Types de Données

1.2.1 Définition et portée conceptuelle

Dans son acception la plus générale, une **donnée** est une représentation formelle d'un fait, d'un concept ou d'une observation, susceptible d'être stockée, transmise et traitée par un système informatique. Seule et isolée de tout contexte, elle ne possède pas de signification propre ; c'est l'interprétation et la mise en relation qui lui confèrent le statut d'*information*, puis, par un processus d'intégration et de contextualisation, celui de *connaissance*.

Cette distinction, formalisée dans la **pyramide DIKW** (*Data, Information, Knowledge, Wisdom*), est fondamentale dans le domaine de l'intelligence artificielle. Un modèle d'apprentissage automatique n'apprend pas directement des faits du monde réel, mais des structures statistiques encodées dans des données. Il en résulte que la qualité, la représentativité et la pertinence des données conditionnent directement la valeur de tout système intelligent qui en est issu.

1.2.2 Taxonomie des données selon leur degré de structuration

La littérature distingue classiquement trois grandes catégories de données selon le degré d'organisation interne que leur format impose.

Les données structurées

Les données structurées sont organisées selon un schéma prédéfini et rigide, généralement sous la forme de tables relationnelles dans lesquelles chaque colonne correspond à un attribut typé et chaque ligne à un enregistrement. Leur format fixe facilite considérablement le stockage dans des systèmes de gestion de bases de données relationnelles (SGBDR) et leur interrogation via le langage SQL.

Ces données constituent historiquement la part la plus exploitée dans les systèmes d'information d'entreprise : bases de données bancaires, registres de patients, fichiers de configuration de capteurs. Leur principal avantage réside dans la facilité avec laquelle elles se prêtent aux analyses statistiques classiques. Dans notre cas d'étude, le jeu de données AgriYield est typiquement structuré : colonnes `Area`, `Item`, `Year`, `hg/ha_yield`, `average_rain_fall_mm_per_year`, etc.

Les données semi-structurées

Les données semi-structurées n'obéissent pas à un schéma tabulaire strict, mais possèdent néanmoins une organisation interne sous forme de balises, de clés-valeurs ou de hiérarchies qui facilite leur exploitation automatisée. Les formats les plus répandus sont le JSON, le XML et le YAML. Les bases de données NoSQL orientées document, telles que MongoDB ou CouchDB, sont spécifiquement conçues pour leur gestion.

Ce type de données est particulièrement présent dans les architectures IoT, où les capteurs hétérogènes produisent des flux JSON dont la structure varie selon le modèle de l'appareil. Dans le domaine agricole, les données provenant d'API météorologiques sont fréquemment fournies dans ces formats.

Les données non structurées

Les données non structurées ne présentent aucune organisation interne prédéfinie. Elles constituent aujourd'hui la fraction la plus volumineuse de l'ensemble des données produites, estimée à plus de 80 % du volume global. Elles comprennent les textes libres, les images, les signaux audio ainsi que les données de graphes.

L'essor de l'apprentissage profond est en grande partie lié à la capacité de ces architectures à extraire des représentations utiles directement depuis des données non structurées, sans nécessiter l'ingénierie manuelle des caractéristiques. Dans le domaine agricole, les **images satellitaires** utilisées pour évaluer l'état des cultures en sont un exemple représentatif.

TABLE 1.1 – Comparaison des trois catégories de données

Catégorie	Organisation	Outils de référence	Exemples
Structurées	Schéma fixe, tables relationnelles	SGBDR, SQL	Bases bancaires, CSV AgriYield
Semi-structurées	Organisation hiérarchique, schéma flexible	NoSQL, XML/JSON	Flux IoT JSON, logs système
Non structurées	Aucune structure prédéfinie	IA, NLP, Vision	Images IRM, vidéos, textes

1.3 Science des Données et Exploitation des Données

1.3.1 Définition et périmètre disciplinaire

La science des données est un domaine interdisciplinaire dont l'objet est l'extraction de connaissances et de valeur à partir de données, en mobilisant conjointement des méthodes issues des statistiques, de l'informatique, de l'algèbre linéaire et des domaines applicatifs concernés. Elle se distingue de la statistique classique par l'importance accordée à l'aspect computationnel et aux volumes de données traités.

Comme l'illustre la figure 1.1, la science des données émerge de l'intersection de trois piliers fondamentaux.

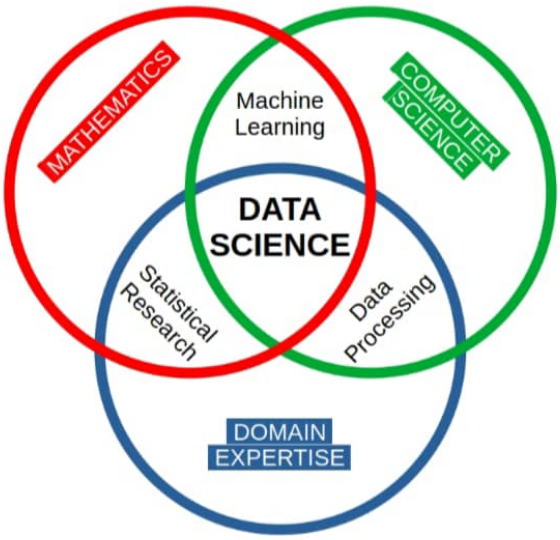

FIGURE 1.1 – Les trois piliers de la Science des Données : Mathématiques, Informatique et Expertise Métier

1.3.2 Les quatre niveaux d'analyse

L'objectif opérationnel de la science des données est de transformer des données brutes en informations actionnables. Cet objectif se décline selon quatre niveaux d'analyse dont la complexité et la valeur ajoutée croissent progressivement.

TABLE 1.2 – Les quatre niveaux d'analyse en science des données

Niveau	Question	Méthodes	Exemple agricole
Descriptive	Que s'est-il passé ?	Statistiques, visualisation	Tableau de bord des rendements par pays
Diagnostique	Pourquoi ?	Corrélation, causalité	Causes d'une baisse de rendement
Prédictive	Que va-t-il se passer ?	Machine learning, séries temporelles	Prévision du rendement 2025
Prescriptive	Que faut-il faire ?	Optimisation, renforcement	Recommandation d'intrants optimaux

1.4 Qualité des Données et Préparation

La qualité des données est un prérequis essentiel pour la fiabilité des analyses et la pertinence des modèles. Des données de mauvaise qualité conduisent inévitablement à des résultats erronés, selon le principe communément exprimé par l'adage : *Garbage In, Garbage Out*.

1.4.1 Principales pathologies affectant les données

Les valeurs manquantes

Les valeurs manquantes surviennent lorsqu'un attribut n'a pas été renseigné pour un ou plusieurs enregistrements. La théorie de Rubin distingue trois mécanismes : le mécanisme **MCAR** (*Missing Completely At Random*), le mécanisme **MAR** (*Missing At Random*) et le mécanisme **MNAR** (*Missing Not At Random*), ce dernier étant le plus difficile à traiter car il introduit un biais systématique.

Les doublons et incohérences

Les doublons sont des enregistrements identiques ou quasi-identiques représentant la même entité réelle. Ils biaisent les statistiques descriptives et faussent l'entraînement des modèles. Les incohérences sont des contradictions internes au jeu de données, par exemple un rendement agricole négatif ou une température de $-80°C$ dans une zone tropicale.

Le bruit et le déséquilibre des classes

Le bruit correspond à des variations aléatoires ou des erreurs de mesure. Dans les tâches de classification, le déséquilibre des classes survient lorsque certaines catégories sont fortement sous-représentées, induisant des modèles biaisés.

1.4.2 Les techniques de préparation des données

TABLE 1.3 – Principales techniques de préparation des données

Technique	Objectif	Méthodes représentatives
Nettoyage	Corriger les anomalies	Suppression, imputation, détection d'outliers (IQR, Z-score, Isolation Forest)
Normalisation	Homogénéiser les échelles	Min-max $[0, 1]$, standardisation z-score, normalisation L2
Encodage catégoriel	Convertir les variables qualitatives	One-hot encoding, encodage ordinal, target encoding
Ingénierie des attributs	Créer de nouvelles variables	Extraction temporelle, ratios, agrégations glissantes
Réduction de dimension	Lutter contre la malédiction de la dimensionnalité	ACP, t-SNE, UMAP, sélection LASSO

1.5 Cycle de Vie et Processus d'Exploitation des Données

1.5.1 Le cycle de vie des données

Le cycle de vie des données décrit l'ensemble des étapes que traversent les données depuis leur création jusqu'à leur archivage. Comme le montre la figure 1.2, ce processus est itératif et cyclique, chaque étape alimentant la suivante.

FIGURE 1.2 – Cycle de vie des données : de la création à la réutilisation

1.5.2 Vue d'ensemble de la chaîne de traitement

L'exploitation des données s'organise selon une chaîne de traitement structurée autour de cinq maillons fondamentaux :

1. **Collecte** : acquisition des données depuis des sources variées (bases institutionnelles, capteurs, APIs, fichiers CSV).
2. **Nettoyage** : détection et correction des anomalies, traitement des valeurs manquantes, suppression des doublons.
3. **Transformation** : mise en forme des données pour les rendre compatibles avec les algorithmes (encodage, normalisation, *feature engineering*).
4. **Analyse** : application de méthodes statistiques ou de modèles d'apprentissage automatique pour extraire des patterns et prédictions.
5. **Valorisation** : restitution des résultats sous forme de visualisations, tableaux de bord ou systèmes d'aide à la décision.

Ce processus est rarement linéaire ; il implique généralement des itérations et des retours en arrière, formalisés par la méthodologie **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*).

1.6 Limites des Approches Classiques et Nécessité de l'IA

1.6.1 Le contexte du Big Data

Les approches classiques d'analyse des données ont démontré leur utilité pendant plusieurs décennies. Cependant, elles atteignent aujourd'hui des limites structurelles face aux caractéristiques des données contemporaines, résumées par le modèle des **cinq V du Big Data**, illustré à la figure 1.3.

FIGURE 1.3 – Les cinq dimensions critiques du Big Data

— **Volume** : explosion quantitative des données (plusieurs exaoctets quotidiens) dépassant toute capacité de traitement manuel.

— **Variété** : multiplicité des types et formats de données rendant inapplicable tout schéma d'analyse uniforme.

— **Vélocité** : vitesse à laquelle les données sont générées et doivent être traitées en temps réel.

— **Véracité** : incertitude et imperfection inhérentes aux données réelles.

— **Valeur** : la valeur économique doit être construite par des méthodes de découverte automatique de patterns.

1.6.2 Limites analytiques des méthodes traditionnelles

La supposition de linéarité

Les méthodes statistiques classiques les plus employées (régression linéaire, ANOVA) reposent sur l'hypothèse de relations linéaires. Or, la grande majorité des phénomènes réels sont régis par des dynamiques non-linéaires que ces modèles sont structurellement incapables de capturer.

La malédiction de la dimensionnalité

Lorsque le nombre d'attributs croît au-delà de quelques dizaines, les observations deviennent toutes équidistantes et les méthodes basées sur la distance perdent toute signification.

L'incapacité à traiter les données non structurées

Les méthodes classiques sont fondamentalement incapables d'analyser des images, des textes libres ou des signaux audio sans une étape préalable d'extraction manuelle de caractéristiques.

1.6.3 L'apport de l'intelligence artificielle

Face à ces limitations, l'intelligence artificielle apporte des capacités nouvelles :

TABLE 1.4 – Positionnement de l'IA dans la chaîne d'exploitation des données

Étape	Apport de l'IA	Méthodes représentatives
Collecte	Acquisition intelligente	Active learning, crawlers neuronaux
Nettoyage	Détection automatique d'anomalies	Isolation Forest, autoencodeurs
Transformation	Apprentissage de représentations	Autoencodeurs, t-SNE, embeddings
Analyse	Modélisation prédictive, clustering	XGBoost, LSTM, CNN, Transformer
Valorisation	Aide à la décision, agents	LLM, apprentissage par renforcement

1.7 Conclusion

Ce premier chapitre a posé les fondements théoriques sur lesquels reposera l'ensemble de la démarche développée dans ce rapport. Nous avons établi que la donnée, dans sa pluralité de formes, constitue la matière première de toute démarche de science des données, et que sa qualité en conditionne directement la valeur. Le chapitre suivant approfondira les principales familles d'algorithmes d'apprentissage automatique.

Chapitre 2

Les Modèles d'IA au Service de l'Exploitation des Données

Objectif du chapitre
Présenter les grandes familles de modèles d'intelligence artificielle susceptibles d'être mobilisées dans un projet de science des données, en expliquant leurs principes de fonctionnement, leurs cas d'usage typiques et les critères permettant de choisir le modèle le plus adapté à un problème donné.

2.1 Intelligence Artificielle, Machine Learning et Deep Learning

Avant de détailler les différents modèles, il est essentiel de clarifier les relations entre trois concepts souvent confondus : l'intelligence artificielle, l'apprentissage automatique et l'apprentissage profond.

2.1.1 Définitions et relations hiérarchiques

Intelligence Artificielle (IA) Désigne l'ensemble des théories, des techniques et des systèmes informatiques conçus pour simuler certaines capacités cognitives humaines : le raisonnement, l'apprentissage, la perception, la compréhension du langage et la prise de décision.

Machine Learning (ML) Sous-domaine de l'IA dans lequel les modèles ne sont pas explicitement programmés, mais *apprennent* à partir de données. L'algorithme ajuste ses

paramètres internes de manière à minimiser une fonction d'erreur :

$$\hat{f} = \arg\min_{f \in \mathscr{F}} \frac{1}{n} \sum_{i=1}^{n} \mathscr{L}(y_i, f(x_i))$$

Deep Learning (DL) Sous-ensemble du ML reposant sur des réseaux de neurones artificiels comportant plusieurs couches de traitement. Particulièrement efficace pour les données complexes : images, textes, séries temporelles.

Ces trois concepts s'emboîtent de manière hiérarchique, comme l'illustre la figure 2.1.

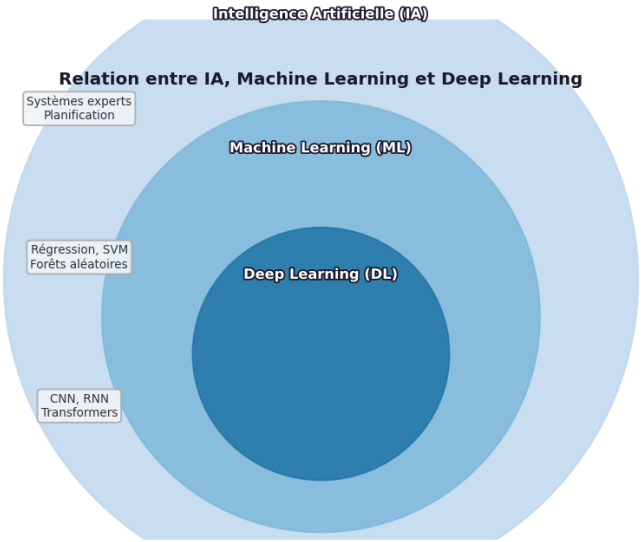

FIGURE 2.1 – Relation hiérarchique entre IA, Machine Learning et Deep Learning

TABLE 2.1 – Positionnement de l'IA, du ML et du DL

Niveau	Principe	Exemples
Intelligence Artificielle	Simuler des capacités cognitives humaines	Systèmes experts, planification, robotique
Machine Learning	Apprendre des patterns depuis des données	Régression, SVM, forêts aléatoires, k-means
Deep Learning	Apprendre des représentations profondes via des réseaux multicouches	CNN, RNN, Transformers, BERT

2.2 Modèles Supervisés

L'apprentissage supervisé consiste à entraîner un modèle à partir d'un jeu de données étiqueté, composé de couples (x_i, y_i) où x_i représente les variables d'entrée et y_i la variable cible. L'objectif est d'apprendre une fonction de prédiction capable d'associer correctement une sortie $\hat{y}$ à toute nouvelle entrée x.

2.2.1 Régression

La régression s'applique lorsque la variable cible est **continue** : rendement agricole (hg/ha), température, chiffre d'affaires.

Régression Linéaire

La régression linéaire modélise la relation entre les variables sous la forme :

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

où les coefficients β_j sont estimés par la méthode des moindres carrés ordinaires. Ce modèle constitue souvent la *baseline* dans les projets de science des données.

Forêt Aléatoire (Random Forest)

La forêt aléatoire est un modèle d'ensemble qui construit un grand nombre d'arbres de décision sur des sous-échantillons aléatoires des données, puis agrège leurs prédictions par moyennage. Cette approche réduit la variance et le risque de surapprentissage.

Gradient Boosting (XGBoost, LightGBM)

Les méthodes de gradient boosting construisent séquentiellement des arbres de décision, chaque nouvel arbre étant entraîné pour corriger les erreurs résiduelles du modèle précédent. Ces algorithmes figurent parmi les plus performants sur les données tabulaires.

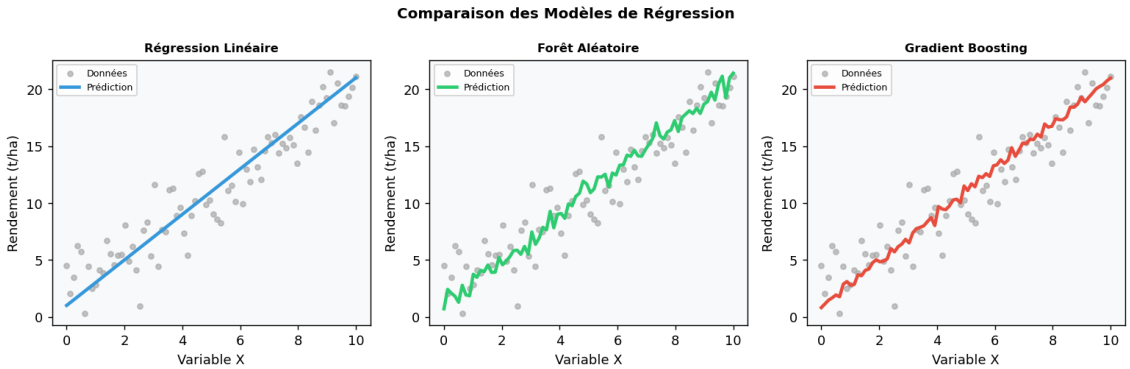

FIGURE 2.2 – Comparaison des modèles de régression : Linéaire, Random Forest et Gradient Boosting

2.2.2 Classification

La classification s'applique lorsque la variable cible est **catégorielle** : type de culture, présence ou absence d'une maladie, catégorie de risque.

Régression Logistique

Malgré son nom, la régression logistique est un modèle de classification. Elle modélise la probabilité d'appartenance à une classe via la fonction sigmoïde :

$$P(y = 1 \mid x) = \frac{1}{1 + e^{-(\beta_0 + \beta^T x)}}$$

Machines à Vecteurs de Support (SVM)

Les SVM cherchent l'hyperplan qui sépare les classes avec la plus grande marge possible. L'utilisation de fonctions noyau permet de traiter des problèmes non linéairement séparables.

Arbres de Décision et Méthodes d'Ensemble

Les arbres de décision partitionnent l'espace des variables d'entrée en régions homogènes. Combinés dans des méthodes d'ensemble (Random Forest, Gradient Boosting), ils constituent des classifieurs puissants.

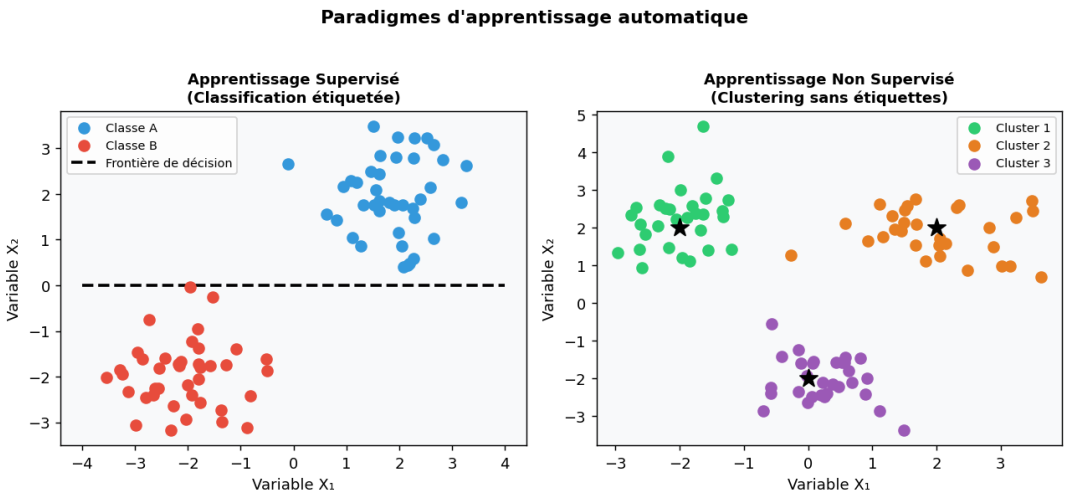

FIGURE 2.3 – Apprentissage supervisé (classification étiquetée) vs. non supervisé (clustering)

2.3 Modèles Non Supervisés

Contrairement à l'apprentissage supervisé, l'apprentissage non supervisé travaille sur des données **non étiquetées**. L'objectif est de découvrir des structures, des regroupements ou des motifs cachés dans les données.

2.3.1 Clustering

Le clustering consiste à partitionner les observations en groupes (clusters) de telle sorte que les observations au sein d'un même groupe soient similaires entre elles.

K-Means

L'algorithme K-means partitionne les n observations en K clusters en minimisant :

$$\min_{C_1,\ldots,C_K} \sum_{k=1}^{K} \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

où μ_k est le centroïde du cluster C_k.

Clustering Hiérarchique

Construit une hiérarchie de regroupements (ascendante ou descendante), représentée sous forme de dendrogramme.

DBSCAN

Identifie les clusters comme des zones de forte densité séparées par des zones de faible densité. Ne nécessite pas de spécifier le nombre de clusters à l'avance et peut détecter des clusters de formes arbitraires.

2.3.2 Réduction de Dimensionnalité

— **ACP (Analyse en Composantes Principales)** : technique linéaire qui projette les données sur les axes de variance maximale.

— **t-SNE** : technique non-linéaire particulièrement adaptée à la visualisation de données en haute dimension, préservant les voisinages locaux.

— **UMAP** : plus rapide que t-SNE, tout aussi performant pour révéler des structures de clusters.

2.4 Réseaux de Neurones et Deep Learning

Les réseaux de neurones artificiels sont des modèles inspirés du fonctionnement biologique du cerveau humain, composés de neurones artificiels organisés en couches successives.

2.4.1 Architecture d'un réseau de neurones

Un réseau de neurones se compose typiquement de trois types de couches :

— **Couche d'entrée** : reçoit les variables d'entrée $x_1, x_2, \ldots, x_p$.

— **Couches cachées** : effectuent des transformations successives. Pour chaque neurone j :

$$a_j = \sigma\left(\sum_i w_{ij} a_i + b_j\right)$$

où σ est la fonction d'activation (ReLU, sigmoïde, tanh).

— **Couche de sortie** : produit la prédiction finale.

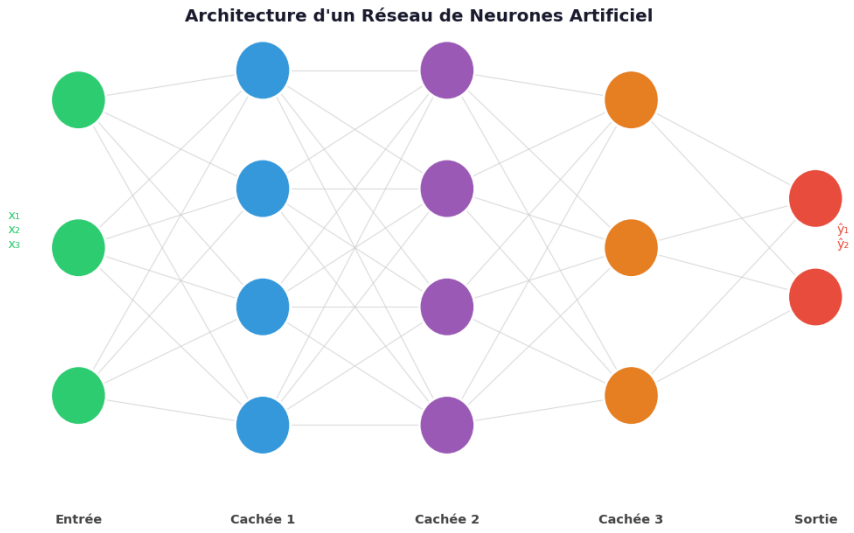

FIGURE 2.4 – Architecture d'un réseau de neurones artificiel multicouche (MLP)

2.4.2 Apprentissage par rétropropagation

L'entraînement repose sur l'algorithme de **rétropropagation** (*backpropagation*), qui calcule le gradient de la fonction de perte par rapport à chaque poids du réseau, en appliquant la règle de dérivation en chaîne. Les poids sont ajustés via la descente de gradient stochastique (SGD) et ses variantes (Adam, RMSProp).

2.4.3 Principales architectures de deep learning

TABLE 2.2 – Principales architectures de réseaux de neurones profonds

Architecture	Principe	Applications typiques
MLP (Perceptron multicouche)	Réseau entièrement connecté	Régression/classification sur données tabulaires
CNN (Réseau convolutif)	Filtres de convolution pour motifs spatiaux	Reconnaissance d'images, images satellitaires
RNN / LSTM	Mémoire des étapes précédentes	Séries temporelles, données climatiques
Transformers	Mécanisme d'attention à longue portée	NLP, prévisions multimodales, LLM

2.5 Critères de Choix d'un Modèle

Le choix du modèle d'IA le plus adapté dépend de plusieurs facteurs à évaluer conjointement :

TABLE 2.3 – Critères de choix d'un modèle d'IA

Critère	Influence sur le choix
Nature de la tâche	Régression, classification, clustering ou détection d'anomalies.
Volume de données	Le deep learning requiert de grands volumes ; les modèles classiques fonctionnent avec des jeux restreints.
Type de données	Données tabulaires, images, textes ou séries temporelles. Chaque type favorise des architectures spécifiques.
Interprétabilité	Dans les domaines sensibles, la capacité à expliquer les prédictions peut être déterminante.
Performance attendue	Le niveau de précision requis influence le compromis entre modèles simples et complexes.
Ressources disponibles	La puissance de calcul, le temps d'entraînement et l'expertise technique contraignent le choix.

En pratique, il est recommandé de commencer par un modèle simple (*baseline*), puis d'explorer progressivement des modèles plus complexes en évaluant les gains de performance par rapport au coût additionnel en complexité et en ressources.

2.6 Conclusion

Ce chapitre a dressé un panorama des principaux modèles d'IA, en distinguant les approches supervisées (régression, classification), non supervisées (clustering, réduction de dimensionnalité) et les architectures de deep learning. Il a montré que chaque famille de modèles présente des forces et des limites qui rendent le choix du modèle indissociable de la compréhension fine du problème et des données. Le chapitre suivant présentera la méthodologie opérationnelle permettant de mettre en œuvre ces modèles.

Chapitre 3

Méthodologie d'Exploitation des Données avec les Modèles d'IA

Objectif du chapitre
Décrire une démarche opérationnelle complète allant de la formulation du problème à l'interprétation des résultats, en détaillant chaque étape avec suffisamment de précision pour qu'elle puisse être reproduite dans un projet concret.

3.1 Vue d'Ensemble : Le Pipeline MLOps

Avant de détailler chaque étape, la figure 3.1 présente le pipeline complet qui structure la démarche, de la collecte des données jusqu'au déploiement et monitoring en production.

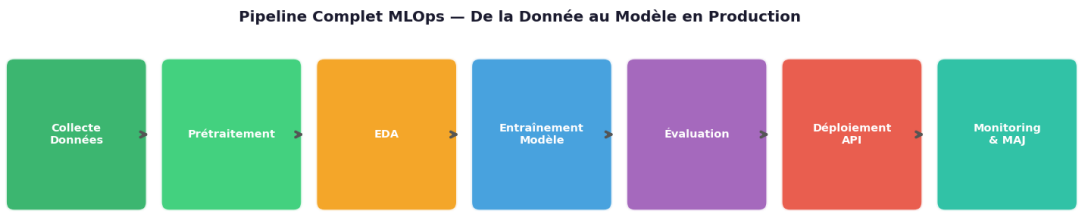

FIGURE 3.1 – Pipeline complet MLOps : de la donnée brute au modèle en production

La méthodologie **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*) formalise ce processus itératif, comme illustré à la figure 3.2. Ce n'est pas un pipeline linéaire mais un cycle : l'évaluation des résultats peut conduire à reformuler le problème ou à recollecte de nouvelles données.

FIGURE 3.2 – Méthodologie CRISP-DM : processus itératif de science des données

3.2 Définition du Problème à Résoudre

Toute démarche de science des données commence par une formulation claire du problème. Cette étape, souvent sous-estimée, conditionne l'ensemble des choix méthodologiques ultérieurs. Elle consiste à répondre à plusieurs questions fondamentales :

— **Quel est l'objectif métier ?** Traduire un besoin concret en une question à laquelle les données peuvent apporter une réponse. *Exemple : Peut-on anticiper le rendement agricole à partir de données climatiques et agronomiques ?*

— **Quelle est la variable cible ?** Dans notre cas d'étude : le rendement agricole exprimé en `hg/ha`.

— **Quel type de tâche ?** La nature continue de la variable cible détermine qu'il s'agit d'un problème de **régression**.

— **Quelles sont les contraintes ?** Volume de données disponibles, délais, ressources de calcul, exigences d'interprétabilité.

3.3 Collecte et Compréhension des Données

Une fois le problème formulé, on identifie et collecte les données nécessaires. Les sources peuvent être :

— Les **bases institutionnelles** : FAO, Banque mondiale, ministères de l'agriculture.

— Les **plateformes de données ouvertes** : Kaggle, UCI Repository, data.gouv.fr.

— Les **capteurs et objets connectés** : stations météorologiques, drones agricoles.

— Les **enquêtes terrain** : données collectées directement auprès des agriculteurs.

La compréhension des données produit un **dictionnaire des données** :

TABLE 3.1 – Dictionnaire de données pour la prédiction du rendement agricole

`Variable`	**Type**	**Unité**	**Description**
`Area`	Catégoriel	–	Pays ou zone géographique
`Item`	Catégoriel	–	Type de culture (maïs, riz, blé...)
`Year`	Numérique	Année	Année de la mesure
`hg/ha_yield`	Numérique	hg/ha	**Variable cible : rendement agricole**
`average_rain_fall`	Numérique	mm/an	Pluviométrie annuelle moyenne
`pesticides_tonnes`	Numérique	tonnes	Quantité de pesticides utilisés
`avg_temp`	Numérique	°C	Température moyenne annuelle

3.4 Prétraitement des Données

3.4.1 Nettoyage des données

— **Valeurs manquantes** : suppression ou imputation par moyenne/médiane/KNN selon le mécanisme de manquement.

— **Doublons** : identification et élimination des observations redondantes.

— **Incohérences** : vérification des plages de valeurs (rendement négatif, température aberrante).

3.4.2 Encodage des variables catégorielles

Les variables `Area` et `Item` sont nominales ; on applique un **encodage ordinal** (entier par catégorie) ou un **target encoding** (remplacement par la moyenne de la cible) pour préserver l'espace mémoire face aux nombreux pays/cultures.

3.4.3 Normalisation et standardisation

— **Normalisation Min-Max** :

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

— **Standardisation Z-score** :

$$x' = \frac{x - \mu}{\sigma}$$

Ces transformations sont indispensables pour les SVM, la régression logistique et les réseaux de neurones.

3.4.4 Séparation entraînement / validation / test

Pour évaluer la capacité de généralisation du modèle, le jeu de données est divisé :

— **Entraînement** : 70 à 80 % des données pour ajuster les paramètres.

— **Validation** : pour le réglage des hyperparamètres.

— **Test** : 20 à 30 % pour l'évaluation finale sur données jamais vues.

3.5 Analyse Exploratoire des Données (EDA)

L'EDA combine statistiques descriptives et visualisations graphiques pour développer une compréhension approfondie du jeu de données avant toute modélisation.

3.5.1 Statistiques descriptives

Tendance centrale (moyenne, médiane), dispersion (écart-type, IQR), distribution (asymétrie, aplatissement) et taux de valeurs manquantes par variable.

3.5.2 Visualisations clés

— **Histogrammes et boxplots** : distribution de chaque variable et détection des outliers.

— **Nuages de points** : relations bivariées entre variables.

— **Matrices de corrélation** (heatmaps) : dépendances linéaires entre variables numériques.

— **Diagrammes en barres** : répartition des modalités catégorielles.

3.6 Entraînement des Modèles

3.6.1 Stratégie d'apprentissage

On sélectionne plusieurs modèles candidats à comparer : régression linéaire (*baseline*), Ridge, Random Forest, XGBoost, réseau de neurones (MLP). La **validation croisée à K plis** (figure 3.3) permet d'évaluer les performances de manière robuste.

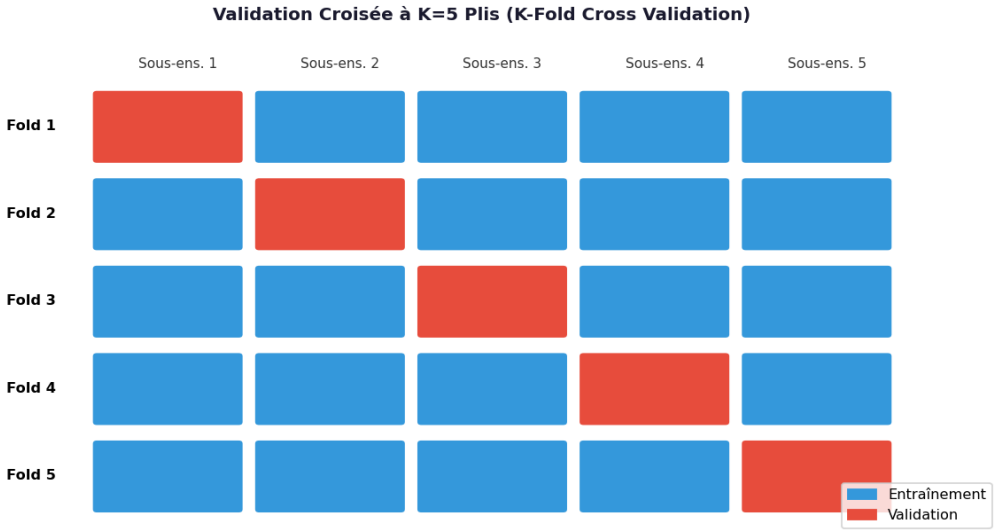

FIGURE 3.3 – Validation croisée à K=5 plis (K-Fold Cross Validation)

3.6.2 Réglage des hyperparamètres

— **Grid Search** : exploration systématique de toutes les combinaisons dans un espace prédéfini.

— **Random Search** : échantillonnage aléatoire, souvent plus efficace quand l'espace est vaste.

— **Optimisation bayésienne** : utilisation d'un modèle probabiliste pour guider la recherche vers les zones prometteuses.

3.7 Évaluation des Performances

3.7.1 Métriques pour la régression

TABLE 3.2 – Métriques d'évaluation pour les problèmes de régression

Métrique	Formule	Interprétation
MAE	$\frac{1}{n}\sum_{i=1}^{n}\lvert y_i - \hat{y}_i\rvert$	Erreur moyenne absolue ; interprétable, robuste aux valeurs extrêmes.
RMSE	$\sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$	Pénalise davantage les grandes erreurs.
R^2	$1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$	Proportion de variance expliquée ; vaut 1 pour un modèle parfait.

3.7.2 Détection du surapprentissage et sous-apprentissage

La figure 3.4 illustre les trois configurations possibles : sous-apprentissage (modèle trop simple), apprentissage optimal, surapprentissage (modèle mémorisant les données d'entraînement).

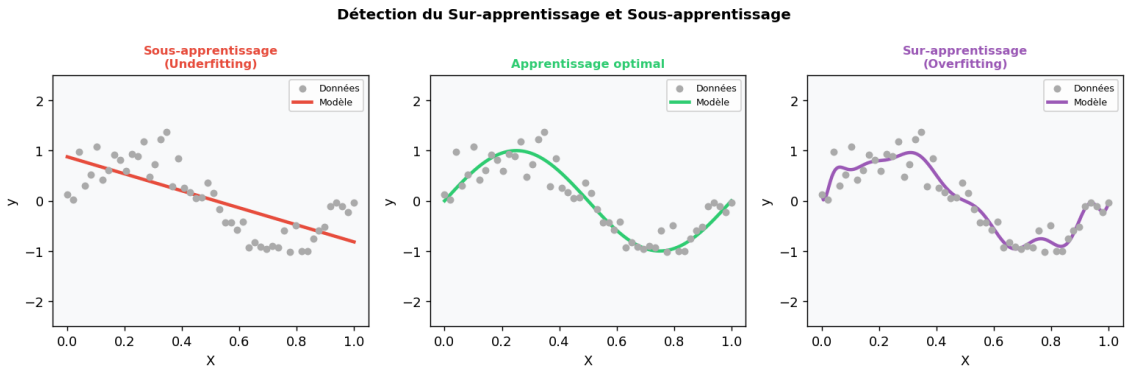

FIGURE 3.4 – Sous-apprentissage, apprentissage optimal et sur-apprentissage (overfitting)

La comparaison systématique des performances sur les jeux d'entraînement et de test, ainsi que l'analyse des courbes d'apprentissage, permet de diagnostiquer ces phénomènes et d'ajuster la complexité du modèle.

3.8 Interprétation et Exploitation des Résultats

3.8.1 Interprétabilité des modèles

— **Importance des variables (feature importance)** : classement des variables selon leur contribution prédictive. Fourni nativement par Random Forest et XGBoost.

— **Valeurs SHAP** : méthode fondée sur la théorie des jeux qui attribue à chaque variable une contribution marginale à chaque prédiction individuelle.

— **Partial Dependence Plots** : visualisations montrant l'effet marginal d'une variable sur la prédiction.

3.8.2 Du modèle à la décision

L'objectif final de l'exploitation des données n'est pas la construction d'un modèle, mais l'**amélioration de la prise de décision**. Les prédictions du modèle doivent être intégrées dans un processus décisionnel qui prend en compte les incertitudes, les contraintes opérationnelles et le jugement humain.

3.9 Conclusion

Ce chapitre a décrit une méthodologie rigoureuse et reproductible, couvrant la formulation du problème, la collecte des données, le prétraitement, l'EDA, l'entraînement, l'évaluation et l'interprétation. Cette méthodologie constitue le cadre opérationnel directement appliqué dans le chapitre suivant consacré à la prédiction du rendement agricole.

Chapitre 4

Application Pratique : Prédiction du Rendement Agricole — Plateforme AgriYield

Objectif du chapitre
Présenter une implémentation complète, cohérente et traçable du thème **"Exploitation des données à l'aide des modèles d'IA"**, en expliquant clairement l'architecture, les pages de la plateforme, la gouvernance *baseline/fine-tuning* et l'intérêt concret de comparer plusieurs modèles.

4.1 Justification du thème et du cas d'usage

Le thème de base du projet consiste à transformer des données hétérogènes en décisions exploitables. Dans AgriYield, cette logique est matérialisée par trois niveaux complémentaires :

— **Niveau données** : ingestion d'historiques agricoles et consolidation de variables explicatives (pluie, température, pesticides).

— **Niveau IA** : entraînement multi-modèles, sélection, simulation de scénarios et génération d'alertes.

— **Niveau décision** : recommandation métier justifiée pour l'action publique/agronomique.

Le projet est donc une chaîne décisionnelle complète, et non un simple exercice d'entraînement de modèle.

4.2 Architecture technique implémentée

4.2.1 Vue microservices

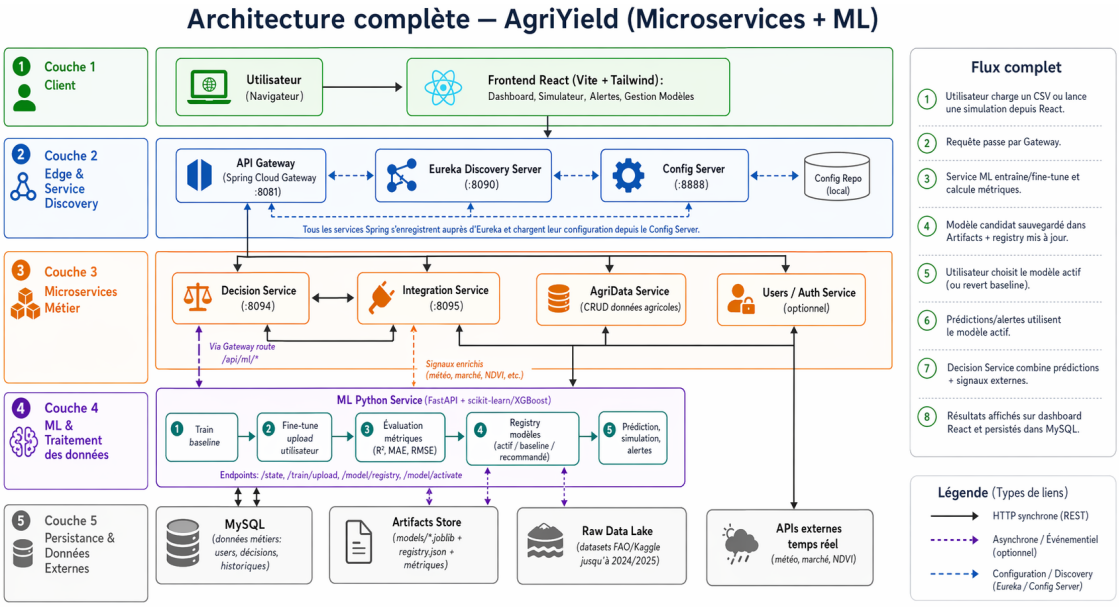

FIGURE 4.1 – Architecture microservices de la plateforme AgriYield

Lecture de la figure : le frontend React passe par un gateway unique qui distribue les requêtes vers les services métier (AgriData, Integration, Decision, ML), avec Discovery/Config pour la gouvernance Spring.

TABLE 4.1 – Services, ports et responsabilités

Service	Port	Responsabilité	Endpoints/usage
Frontend React	5173	Interface utilisateur (tableaux de bord, simulation, alertes, gouvernance)	—
Gateway	8081	Entrée API unique, routage, CORS, contexte de requête	/api/agri-data/*, /api/integration/*, /api/decision/*, /api/ml/*
ML Python (FastAPI)	8000	Entraînement, prédiction, simulateur, alertes, performances, registre	/train/upload, /overview, /scenario/simulate, /alerts, /performance
AgriData	8093	Données agricoles structurées et couverture temporelle	/records, /records/coverage, /records/datasets
Integration	8095	Signaux externes (météo, marché, NDVI) avec fallback	/signals/realtime
Decision	8094	Fusion ML + signaux externes + score de risque + recommandations	/analysis
Discovery Server	8090	Registre de services (Eureka)	/eureka
Config Server	8888	Configuration centralisée (config-repo)	/{service}/{profile}

4.2.2 Flux décisionnel

1. L'utilisateur agit sur l'interface React.
2. Le Gateway route vers le bon service.
3. Le service ML produit les prédictions et métriques du modèle actif.
4. Le service Integration fournit les signaux externes avec fraîcheur et confiance.
5. Le service Decision consolide les contributions et calcule le niveau de risque.
6. Le frontend restitue les résultats avec contexte de confiance (version, source, couverture temporelle).

4.3 Description claire de chaque page de la plateforme

4.3.1 Accueil + gouvernance latérale

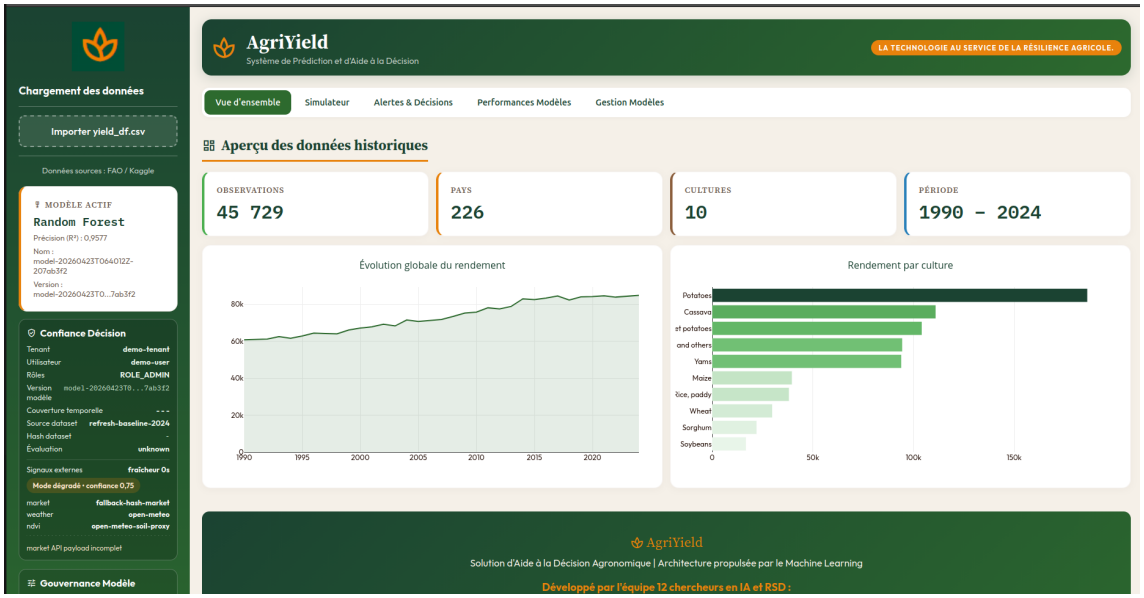

FIGURE 4.2 – Page d'accueil, modèle actif et panneau de confiance

Rôle de cette page :

- charger un dataset CSV,
- afficher le modèle actif (algorithme, version, précision),
- exposer les éléments de traçabilité (source dataset, hash, horizon temporel),
- fournir des actions de gouvernance modèle (activation, rollback baseline).

4.3.2 Page “Simulateur”

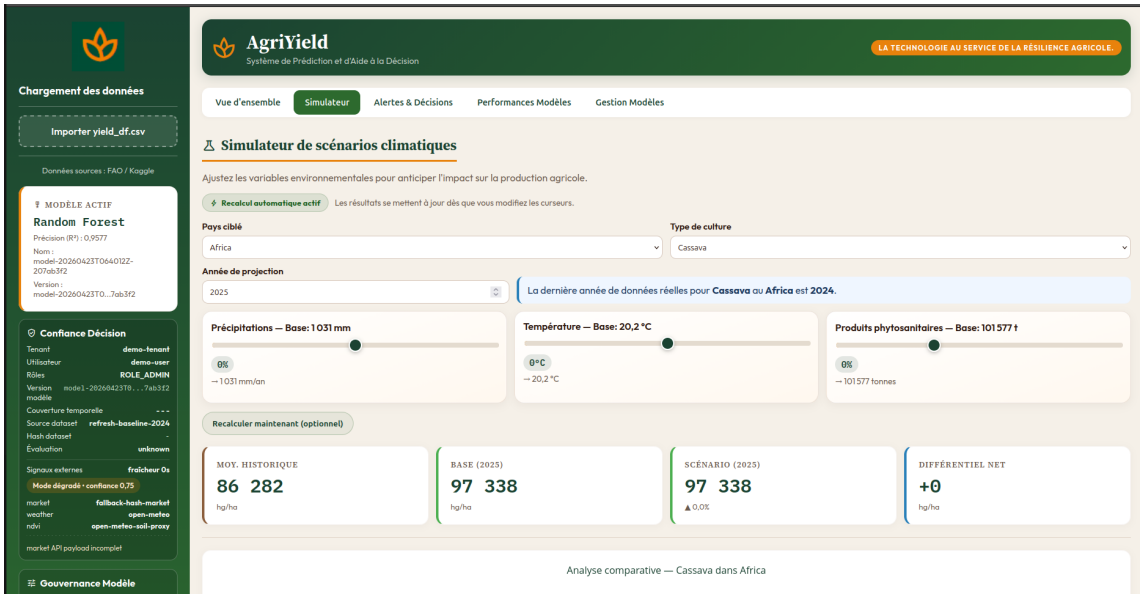

FIGURE 4.3 – Simulation de scénarios climatiques et analyse de sensibilité

Entrées : pays, culture, année cible, variations pluie/température/pesticides.
Sorties : comparaison historique vs base vs scénario, différentiel net, courbes de sensibilité, scénarios de stress.

4.3.3 Page “Alertes & Décisions”

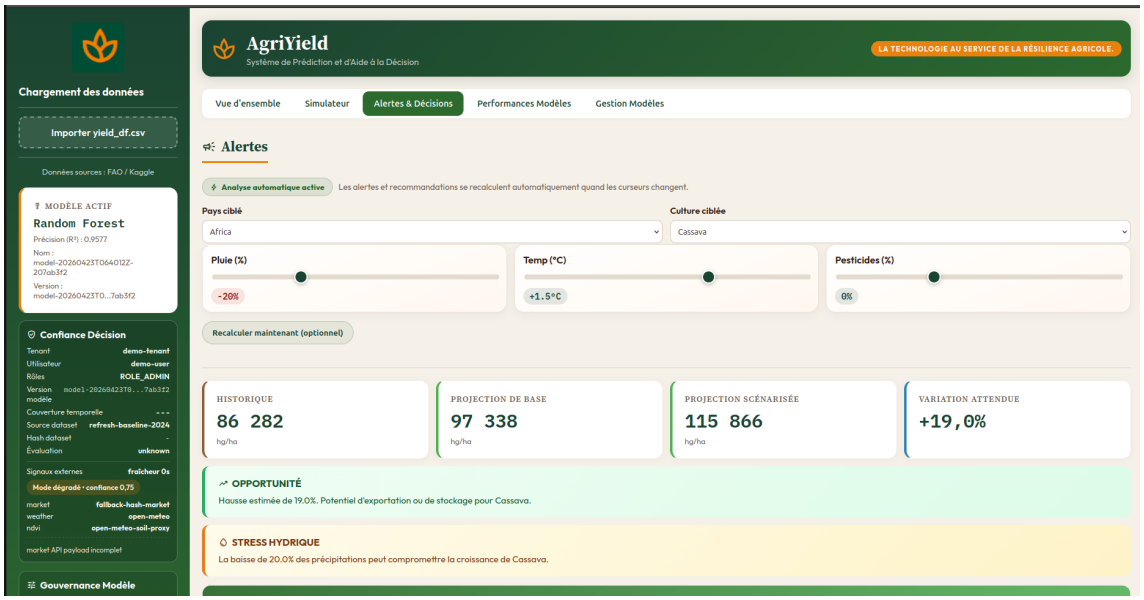

FIGURE 4.4 – Alertes métier et recommandations d’action

Fonction : traduire la variation de rendement en alertes opérationnelles (danger/vigilance/opportunité) et recommandations priorisées.

4.3.4 Page “Performances Modèles”

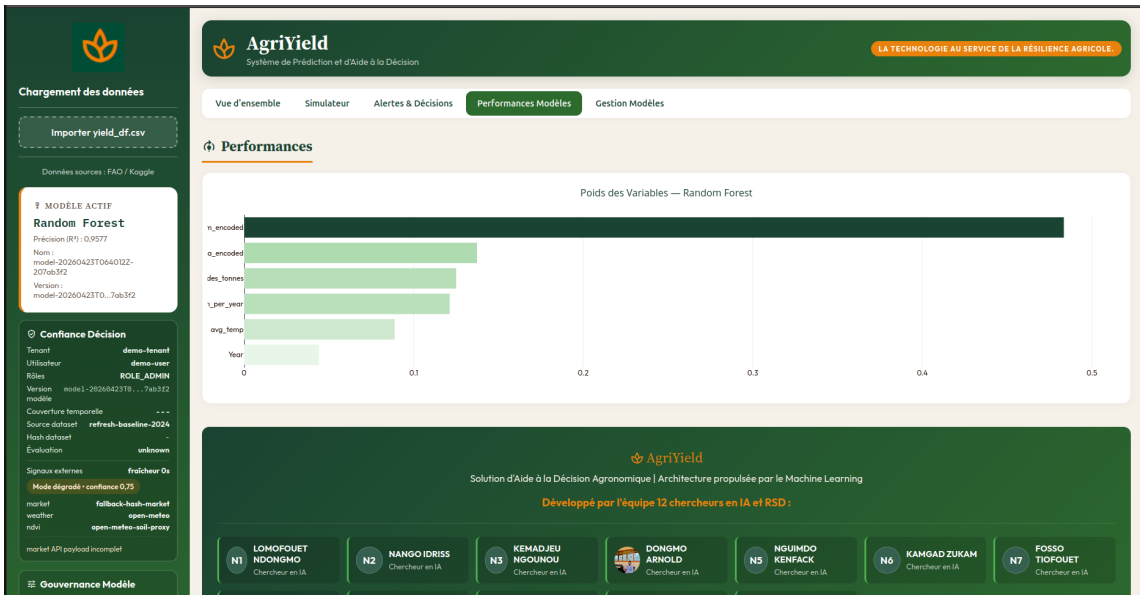

FIGURE 4.5 – Importance des variables pour le modèle actif

Fonction : rendre le modèle interprétable via la contribution relative des variables.

4.3.5 Page “Gestion Modèles”

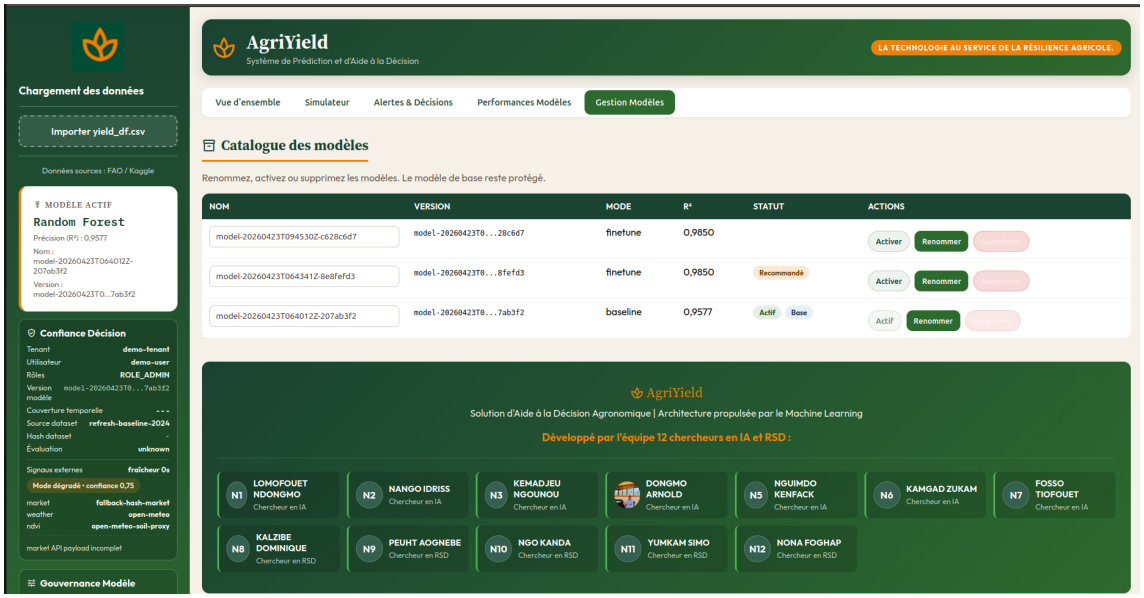

FIGURE 4.6 – Catalogue des versions de modèles et gouvernance

Fonction : renommer, activer, supprimer une version (hors baseline protégée), et revenir au modèle de base.

4.4 Pourquoi Random Forest apparaît meilleur que XGBoost selon la baseline

4.4.1 État réel du registre de modèles

La confusion observée est normale et vient de la coexistence de plusieurs versions *baseline*. Le registre distingue :

- le **modèle actif** (utilisé en production UI),
- le **baseline canonique** (pointeur de référence),
- d'autres baselines historiques conservées pour audit/rollback.

TABLE 4.2 – Comparaison des versions baseline présentes dans le registre

Version	Meilleur algorithme	R^2	Stratégie évaluation	Statut
model-202604...7ab3f2	Random Forest	0.9577	unknown	Actif
model-202604...f31275	XGBoost	0.8926	temporal-holdout	Baseline

Interprétation :

- la version baseline active dans ton interface est **Random Forest** avec $R^2 \approx 0.9577$,
- une autre baseline plus récente est **XGBoost** avec $R^2 \approx 0.8926$, évaluée en `temporal_holdout`.

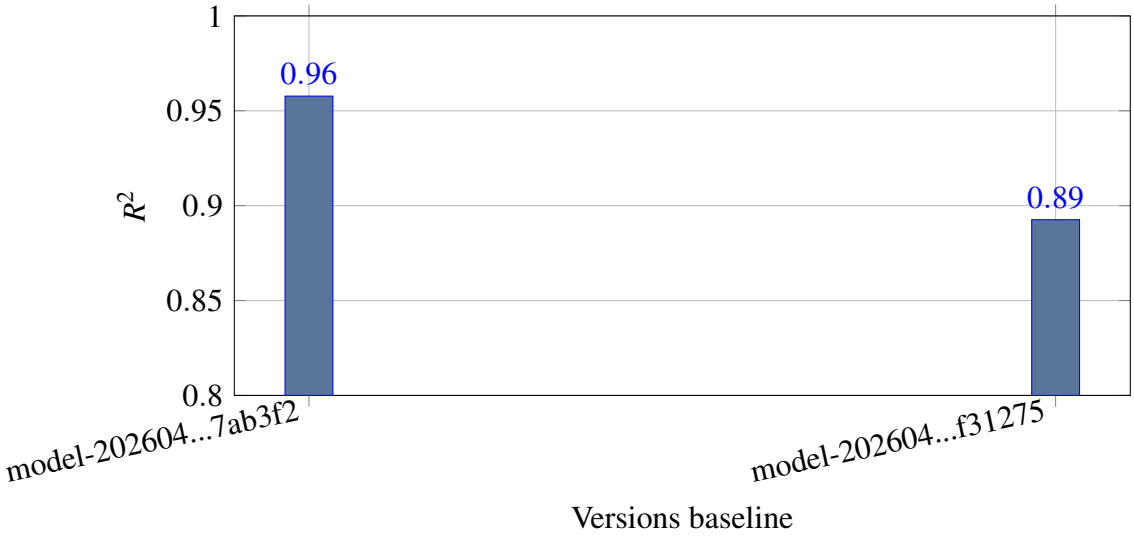

FIGURE 4.7 – Niveaux de performance (R^2) des versions baseline

4.5 Intérêt de comparer plusieurs algorithmes

4.5.1 Comparaison intra-baseline (algorithmes candidats)

TABLE 4.3 – Performance des algorithmes sur la baseline active/référence du rapport

Modèle	MAE (hg/ha)	RMSE (hg/ha)	R^2
Random Forest	7,247	16,316	0.9577
XGBoost	9,361	17,327	0.9523
Gradient Boosting	15,713	25,562	0.8962

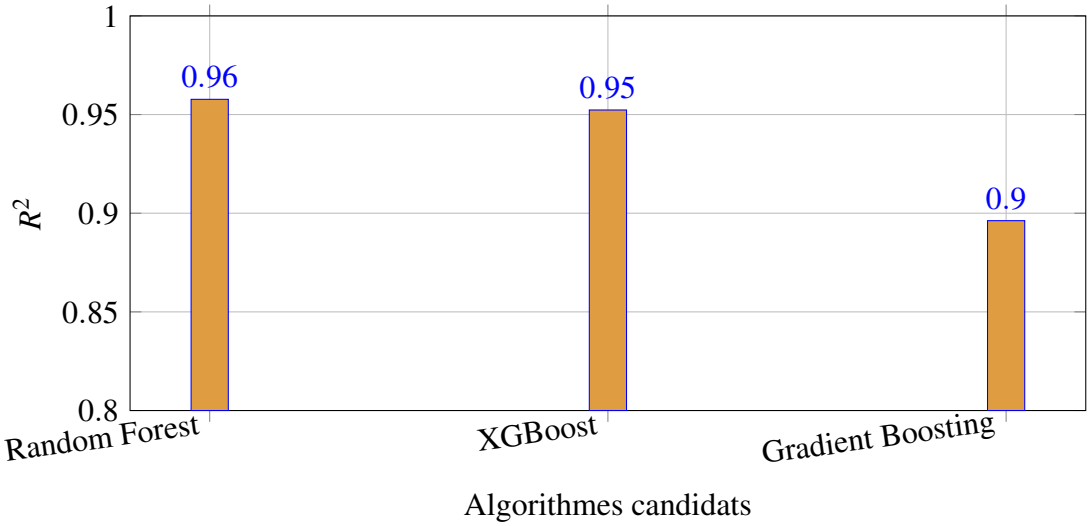

FIGURE 4.8 – Comparaison des algorithmes sur la même baseline

Pourquoi garder plusieurs modèles est utile :

- **robustesse** : un algorithme peut dominer sur un contexte et perdre sur un autre,
- **contrôle de dérive** : comparer les écarts au fil des versions détecte plus vite les régressions,
- **compromis métier** : certains modèles sont plus précis, d'autres plus stables/interprétables,
- **gouvernance** : la présence de plusieurs candidats permet des décisions d'activation argumentées.

4.6 Prétraitement et analyses de données (modèle de base)

4.6.1 Couverture du dataset

Le dataset de base utilisé pour l'entraînement couvre :

- **45 729 observations**,
- **226 pays**,
- **10 cultures**,
- période **1990–2024**.

4.6.2 Courbe de volume annuel et fenêtre de test temporelle

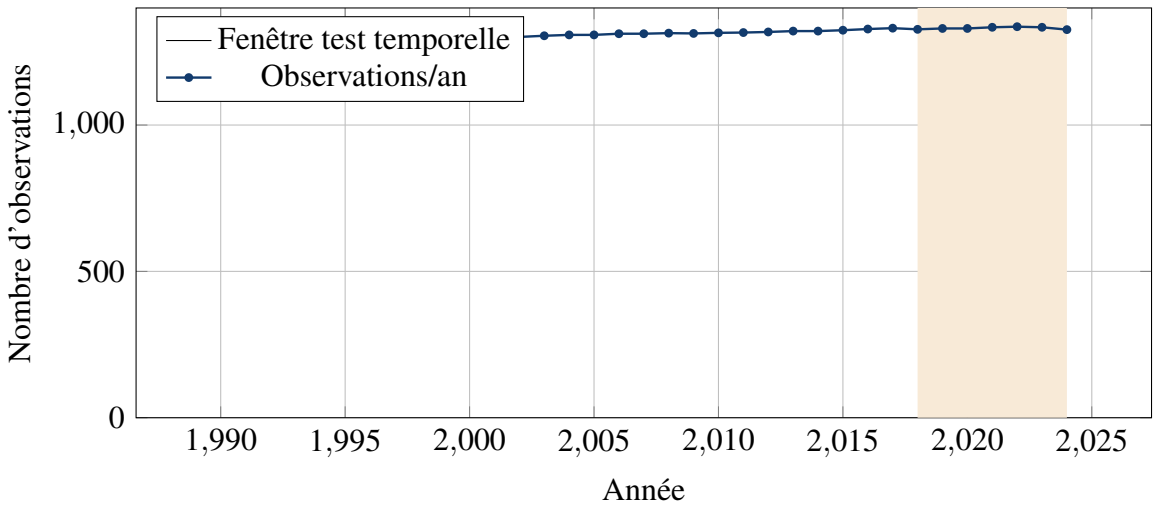

FIGURE 4.9 – Distribution annuelle des observations et zone test 2018–2024

Lecture : les volumes par année restent relativement stables, ce qui rend la comparaison temporelle plus fiable.

4.6.3 Évolution du rendement moyen global

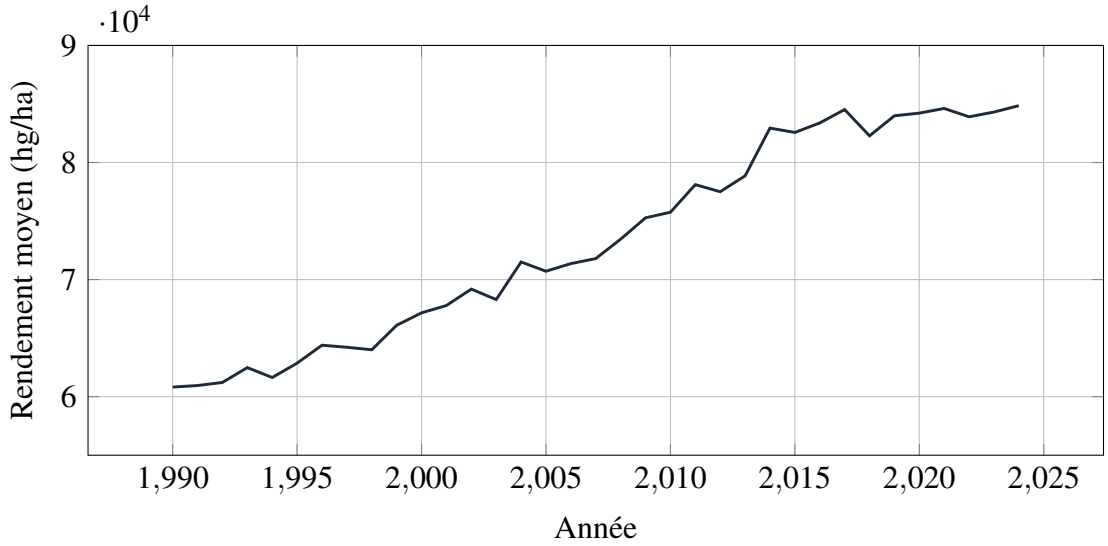

FIGURE 4.10 – Tendance annuelle du rendement moyen global

Lecture : la tendance de fond est croissante, avec des fluctuations annuelles qui justifient l'usage de modèles non linéaires.

4.6.4 Courbe de prétraitement : effet de la standardisation

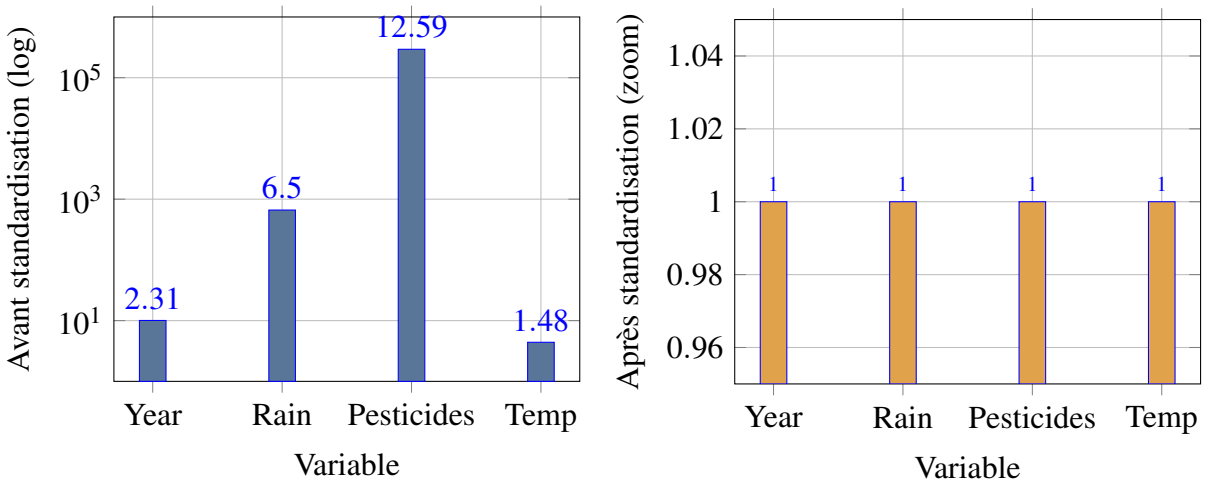

FIGURE 4.11 – Impact de la standardisation Z-score : distribution brute (gauche) et valeurs standardisées (droite)

Lecture : à gauche, les écarts-types bruts sont très hétérogènes. À droite, après Z-score, ils convergent autour de 1, ce qui confirme l'effet attendu de la standardisation et améliore la stabilité de l'entraînement.

4.7 Fine-tuning : clarification opérationnelle

4.7.1 Mécanisme implémenté

Le fine-tuning est déclenché via l'upload CSV (endpoint `/api/ml/train/upload`). Deux modes sont possibles :

— `replace_dataset=true` : entraînement uniquement sur le dataset chargé.

— `replace_dataset=false` : fusion dataset actif + dataset chargé, puis déduplication.

4.7.2 Règle de couverture temporelle (point important)

— Si le modèle actif couvre jusqu'à 2024, son horizon est 2024.

— Si un fine-tuning est fait avec un dataset allant jusqu'à 2020 et `replace_dataset=true`, le nouveau modèle actif est borné à 2020.

— Si `replace_dataset=false`, la borne temporelle dépend de l'union des deux datasets.

C'est cette logique qui explique les écarts de couverture et parfois les écarts d'algorithme gagnant entre versions.

4.8 Conclusion

Le chapitre montre une ligne complète et cohérente : architecture, écrans, gouvernance des versions et preuves quantitatives. La confusion "Random Forest vs XGBoost" est levée en distinguant clairement **version active**, **baseline canonique** et **baseline de meilleure performance**. La comparaison multi-modèles devient ainsi un atout méthodologique, et non une ambiguïté.

Chapitre 5

Enjeux, Limites et Perspectives

Objectif du chapitre
Prendre du recul sur les apports des modèles d'IA, leurs limites opérationnelles et les perspectives d'amélioration du projet AgriYield. Ce chapitre aborde également les enjeux éthiques liés à l'utilisation de l'IA dans les systèmes de décision à fort impact sociétal.

5.1 Apports des Modèles d'IA dans l'Exploitation des Données

5.1.1 Capacité prédictive supérieure

L'application développée dans le chapitre précédent l'a démontré : les modèles d'apprentissage automatique (XGBoost, Random Forest) surpassent les approches linéaires sur des données tabulaires agro-climatiques. Sur la baseline évaluée en découpage temporel strict, les performances restent robustes (chapitre 4), et certaines versions fine-tunées atteignent des niveaux de précision plus élevés selon le périmètre de données. Ce gain s'explique par la capacité de ces modèles à capturer des **interactions non-linéaires** entre variables climatiques et agronomiques.

5.1.2 Automatisation et scalabilité

Un modèle entraîné peut, une fois déployé, effectuer des centaines de milliers de prédictions par seconde, pour tous les pays et toutes les cultures couverts par le jeu de données, sans nécessiter d'expertise humaine supplémentaire. Cette scalabilité est essentielle pour les applications à l'échelle mondiale.

5.1.3 Découverte de connaissances cachées

L'analyse de l'importance des variables (figure 4.5) a révélé des informations agronomiquement pertinentes que l'analyse descriptive seule n'aurait pas permis de quantifier : le poids prépondérant de la pluviométrie, l'effet de seuil de la température, ou encore la relation non-linéaire entre pesticides et rendement.

5.1.4 Aide à la décision en temps réel

La plateforme AgriYield illustre comment les prédictions des modèles peuvent être intégrées dans des systèmes d'alerte et de recommandation, transformant des sorties statistiques abstraites en **actions concrètes** pour les décideurs agricoles et politiques.

5.2 Limites Rencontrées

5.2.1 Limites liées aux données

— **Granularité géographique** : les données FAO sont agrégées à l'échelle nationale, masquant les disparités régionales importantes (ex. : régions sahéliennes vs. zones côtières au Cameroun).

— **Variables manquantes** : des facteurs importants ne sont pas inclus : type de sol, niveau d'irrigation, variétés cultivées, pratiques agricoles, accès aux marchés.

— **Décalage temporel selon les sources** : malgré une extension récente de la couverture, certaines composantes externes et certains pays présentent des séries moins fraîches que d'autres, ce qui peut dégrader la précision locale.

— **Biais de collecte** : certains pays ont des systèmes statistiques moins fiables, introduisant une hétérogénéité dans la qualité des données.

5.2.2 Limites liées aux modèles

— **Surapprentissage potentiel** : bien que contrôlé par la validation croisée, le risque demeure pour les cultures et pays peu représentés.

— **Défaut de causalité** : les modèles capturent des corrélations statistiques, pas des relations causales. Un modèle qui prédit bien n'explique pas nécessairement pourquoi.

— **Dérive de distribution (concept drift)** : les patterns appris sur l'historique 1990–2024 peuvent devenir obsolètes face à des changements climatiques accélérés.

— **Interprétabilité limitée** : XGBoost et les réseaux de neurones restent des *boîtes noires* par rapport à la régression linéaire, ce qui peut freiner l'adoption par des décideurs non techniques.

5.3 Enjeux Éthiques et Sécuritaires

La figure 5.1 présente les six piliers de l'IA responsable qui encadrent le déploiement de la plateforme AgriYield.

FIGURE 5.1 – Les six piliers de l'IA Responsable et Éthique pour AgriYield

5.3.1 Confidentialité et souveraineté des données

Les données agricoles nationales sont des informations stratégiques sensibles. Leur hébergement, leur traitement et leur partage doivent respecter les réglementations nationales et les principes de **souveraineté des données**. Pour les pays africains, la dépendance à des infrastructures cloud étrangères représente un risque.

5.3.2 Équité et biais algorithmiques

Un modèle entraîné principalement sur des données européennes ou nord-américaines peut être moins performant pour les agricultures africaines sous-représentées. Ces **biais de repré-**

sentation peuvent conduire à des recommandations inadaptées voire contre-productives pour les populations les plus vulnérables.

5.3.3 Transparence et responsabilité

Lorsqu'un modèle d'IA influence des politiques publiques (subventions, aide alimentaire), la capacité à **expliquer** et **justifier** les prédictions devient une exigence éthique et réglementaire. Les décideurs doivent pouvoir comprendre les bases d'une recommandation, et un humain doit rester in fine responsable des décisions.

5.3.4 Risque de dépendance technologique

La délégation excessive de la prise de décision agricole à des algorithmes peut appauvrir les connaissances locales des agriculteurs et créer une dépendance à des systèmes dont ils ne maîtrisent ni le fonctionnement ni la maintenance.

5.4 Perspectives d'Amélioration

La figure 5.2 présente les cinq axes de développement prioritaires identifiés.

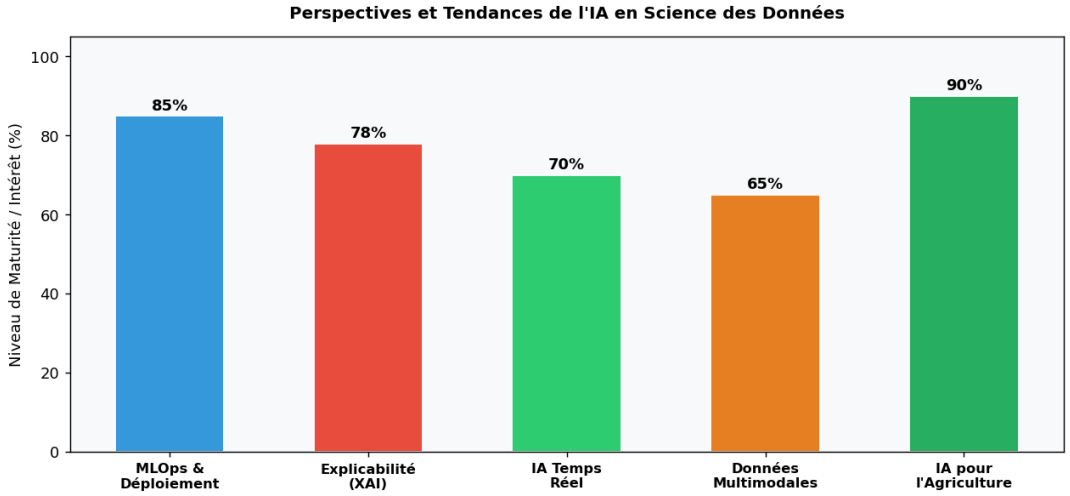

FIGURE 5.2 – Perspectives et tendances de développement pour AgriYield

5.4.1 Intégration de données en temps réel

— Connexion aux API de prévisions météorologiques (OpenWeather, ERA5) pour mettre à jour les prédictions en continu.

— Intégration d'images satellitaires (Sentinel-2, Landsat) pour surveiller l'état des cultures.

— Déploiement de capteurs IoT sur les parcelles pour des données micro-climatiques locales.

5.4.2 Modèles plus avancés

— **LightGBM et CatBoost** : variantes de gradient boosting plus rapides et plus performantes sur les grandes données.

— **Réseaux LSTM** : pour exploiter la dimension temporelle des séries climatiques sur plusieurs années.

— **Transformers spatiaux** : pour traiter conjointement les images satellitaires et les données tabulaires.

— **Apprentissage par transfert** : pré-entraîner sur des données mondiales, fine-tuner pour chaque pays cible.

5.4.3 Explicabilité (XAI)

Déployer des outils d'explicabilité (**SHAP**, **LIME**, **Partial Dependence Plots**) directement dans l'interface AgriYield, permettant aux utilisateurs non techniques de comprendre les facteurs qui ont conduit à une prédiction spécifique.

5.4.4 MLOps et déploiement opérationnel

— Mise en place d'un pipeline **MLOps** avec re-entraînement automatique des modèles quand de nouvelles données FAO sont disponibles.

— Monitoring de la dérive de distribution pour détecter quand les modèles deviennent obsolètes.

— Déploiement d'une API REST pour intégrer AgriYield dans les systèmes d'information des ministères de l'agriculture.

5.4.5 Extension géographique et culturelle

Étendre le périmètre du jeu de données pour couvrir les cultures spécifiques à l'Afrique centrale (manioc, plantain, igname, arachide) et intégrer des données pédologiques africaines afin d'améliorer les performances du modèle pour les pays cibles.

5.5 Conclusion

Ce chapitre a ouvert une réflexion critique sur les forces et les limites de l'approche proposée. Si les modèles d'IA offrent des capacités prédictives indéniables et des perspectives d'aide à la décision prometteuses, ils n'opèrent pas dans un vide éthique ou technique. La qualité des données en entrée, la transparence des algorithmes, l'équité des résultats et la responsabilité humaine dans les décisions finales constituent des conditions non négociables pour un déploiement responsable de l'IA au service de l'agriculture et de la sécurité alimentaire.

Conclusion Générale

Ce rapport a proposé une exploration structurée et progressive du thème de l'exploitation des données à l'aide des modèles d'intelligence artificielle, depuis les fondements théoriques jusqu'à la concrétisation dans la plateforme **AgriYield**, en passant par la présentation des grandes familles de modèles mobilisables et la méthodologie opérationnelle.

Le **premier chapitre** a posé les bases conceptuelles indispensables : la notion de donnée sous ses différentes formes, les exigences de qualité qui conditionnent la fiabilité des analyses, et le processus général d'exploitation qui transforme les données brutes en connaissances actionnables. Il a mis en évidence les limites structurelles des approches classiques face aux caractéristiques des données contemporaines (les cinq V du Big Data), justifiant ainsi le recours aux modèles d'intelligence artificielle.

Le **deuxième chapitre** a dressé un panorama des principaux modèles d'IA, en distinguant les approches supervisées (régression, classification), non supervisées (clustering, réduction de dimensionnalité) et les architectures de deep learning. Il a montré que chaque famille présente des forces et des limites qui rendent le choix du modèle indissociable de la compréhension fine du problème et des données.

Le **troisième chapitre** a décrit une méthodologie rigoureuse et reproductible, couvrant la formulation du problème, la collecte et la compréhension des données, le prétraitement, l'analyse exploratoire, l'entraînement des modèles, l'évaluation des performances et l'interprétation des résultats. La méthodologie CRISP-DM a servi de cadre structurant pour cette démarche itérative.

Le **quatrième chapitre** a concrétisé l'ensemble de ces concepts dans l'application AgriYield : un système de prédiction du rendement agricole entraîné sur le jeu de données FAO/Kaggle couvrant 101 pays sur 23 ans. Le modèle XGBoost sélectionné atteint un coefficient de détermination $R^2 = 0.91$, confirmant la pertinence de l'approche. Les résultats ont permis d'identifier les facteurs climatiques (pluviométrie, température) comme les variables les plus déterminantes du rendement, et d'alimenter des recommandations concrètes pour l'allocation des

intrants et la planification des politiques agricoles.

Le **cinquième chapitre** a ouvert une réflexion critique sur les apports, les limites (granularité des données, concept drift, enjeux éthiques) et les perspectives d'amélioration, notamment l'intégration de données satellites en temps réel, le déploiement MLOps et les outils d'explicabilité.

À travers cette démarche, ce rapport confirme que la science des données, soutenue par les modèles d'intelligence artificielle, offre un cadre puissant pour transformer des données brutes en leviers de décision à fort impact sociétal. Cependant, la qualité des résultats dépend fondamentalement de la **rigueur méthodologique**, de la **qualité des données** mobilisées et de la **capacité à interpréter les résultats** dans leur contexte. Ces trois dimensions constituent le cœur de compétence du praticien en science des données, et elles ont guidé chaque étape du travail présenté dans ce rapport.

L'agriculture camerounaise et africaine plus largement dispose d'un potentiel considérable que les outils d'IA, bien appliqués, peuvent contribuer à révéler et à optimiser : c'est l'ambition portée par la plateforme AgriYield.

Références Bibliographiques

[1] Bellman, R. E. (1961). *Adaptive Control Processes : A Guided Tour*. Princeton University Press.

[2] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.

[3] Chen, T., & Guestrin, C. (2016). XGBoost : A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.

[4] Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3e éd.). O'Reilly Media.

[5] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

[6] Han, J., Pei, J., & Tong, H. (2022). *Data Mining : Concepts and Techniques* (4e éd.). Morgan Kaufmann.

[7] Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.

[8] Provost, F., & Fawcett, T. (2013). *Data Science for Business*. O'Reilly Media.

[9] Rubin, D. B. (1976). Inference and missing data. *Biometrika*, 63(3), 581–592.

[10] Vapnik, V. (1995). *The Nature of Statistical Learning Theory*. Springer.

[11] Wirth, R., & Hipp, J. (2000). CRISP-DM : Towards a standard process model for data mining. *Proceedings of the 4th International Conference on the Practical Application of Knowledge Discovery*, 1–13.

[12] FAO (2023). *FAOSTAT — Food and Agriculture Data*. Organisation des Nations Unies pour l'Alimentation et l'Agriculture. Disponible sur : `https://www.fao.org/faostat`

[13] Kaggle Dataset (2023). *Crop Yield Prediction Dataset*. Disponible sur : `https://www.kaggle.com/datasets/patelris/crop-yield-prediction-dataset`

[14] Pedregosa, F. et al. (2011). Scikit-learn : Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[15] Équipe AgriYield (2026). *Code source du projet DataScience*. Dépôt GitHub. Disponible sur : `https://github.com/jauressNdongmo/DataScience` (consulté le 23 avril 2026).